UNIVERSIDAD NACIONAL DE LA MATANZA

CIENCIAS DE DATOS

Primer Parcial

15 de octubre de 2026

Objetivos

- Desarrollar hipótesis sobre conjunto de datos utilizando técnicas de análisis exploratorio.
- Comprender los algoritmos utilizados en Machine Learning para problemas de clasificación.
- Desarrollar modelos predictivos para resolver problemas en el ámbito de la ciencia de datos.
- Comunicar los resultados del análisis de datos, a través de técnicas de visualización de información adecuadas e interpretables.

Caso Propuesto

La empresa “Business Prop SRL” contrata nuestros servicios para que desarrollemos un modelo que permita predecir si las casas vendidas pagan o no comisión, cuando su precio de venta sea superior a un determinado valor US $300.000.

Para ello, nos comparten un dataset llamado **casas_entrenamiento.csv**, que contiene información de departamentos vendidos en distintos lugares de Argentina y el exterior. Este dataset será el que utilicemos para el entrenamiento del modelo construido.

El dataset de predicción a utilizar es **casas_predecir.csv**, el cual no contiene la etiqueta de la variable clase (por defecto viene indicada como “no paga”).

Los set de datos disponibles son:

- casas_entrenamiento.csv
- casas_predecir.csv

a. Función de ganancia y criterio de aprobación

Por cada predicción que el modelo acierte, la empresa les pagará US$ 100 en concepto de comisión, pero si fallan y cobran una comisión que no deberían, deben darle a Business Prop SRL una compensación de US$ 50.

La evaluación de aprendizaje se considerará aprobada si la ganancia obtenida por el modelo sobre los datos desconocidos supera los U$S 500.000. Como referencia, la ganancia que calculará el modelo construido es sobre el porcentaje de los datos usados para testing (muestra del 30%), con lo que ese valor puede ser alrededor de U$S 166.000.

b. Entregable

- Generar y enviar un archivo de salida **casas_entrega.csv** con los casos donde la medición realizada infiera que se pagará comisión. Para ello, deberá utilizar el dataset que se usó para predecir **casas_predecir.csv**.
- Enviar también el notebook construido con el trabajo desarrollado.
- Es posible entregar hasta dos archivos con distintas predicciones y ambas serán evaluadas por igual, la nota corresponderá a la mejor de las predicciones.

c. Sugerencias

- Algunas variables pueden generar alta dimensionalidad en el dataset, como ser los campos "title","start_date","end_date","created_on",”l3”,”l4” y ”l5”. Sugerimos comenzar con un modelo que no incluya estos campos o bien analizar qué información interesante de los mismos podría contribuir a la mejora de la predicción. Por otro lado, sugerimos que el campo "id" lo usen como índice, con el comando set_index("id").

- Probar diferentes modelos. El objetivo del trabajo es lograr mejorar su modelo original.

- Verificar que NO se aplicó el modelo sobre el dataset de ENTRENAMIENTO por ERROR. Los ids del entregable deben pertenecer al archivo **casas_predecir.csv**.

- Hay que considerar que los campos relacionados a ubicación (l3, l4 y l5), si se desean utilizar, requieren un tratamiento especial (target embedding, feature embedding, clustering) para obtener campos que sean útiles en un modelo de Machine Learning.

Fecha de Entrega: **22**/10/2026