Primer Parcial - Ciencia de Datos (UNLaM)

Plan de trabajo: discrepancias, dudas para el docente y etapas | 15/10/2026 | Entrega: 22/10/2026

Nota: los CSV todavía no fueron abiertos; lo que se dice sobre los datos son hipótesis a verificar.

A. Discrepancias y correcciones respecto del resumen

1. **La ganancia admite otra lectura, y con esa lectura el umbral cambia.** El PDF dice "por cada predicción que el modelo acierte, la empresa les pagará US$ 100", sin aclarar que sean solo los "paga".
   - **Lectura A:** solo cuentan los "paga" entregados (acierto +100, error -50). Se predice "paga" si 100p - 50(1-p) > 0, o sea si **p > 1/3**.
   - **Lectura B:** los ids ausentes del archivo se toman como "no paga" y cada "no paga" acertado también suma 100. Predecir "paga" rinde 100p - 50(1-p) y predecir "no paga" rinde 100(1-p). Conviene "paga" si 150p - 50 > 100 - 100p, o sea si **p > 0,6** (estrategia más conservadora).
   - **Cómo desempatar con datos:** calcular la ganancia del test (30%) con ambas fórmulas; la que dé del orden de US$ 166.000 (la referencia del PDF) probablemente es la que usa la cátedra. Igual conviene consultarlo.
2. **El rol de los US$ 300.000 es ambiguo.** "Predecir si pagan comisión, cuando su precio de venta sea superior a US$ 300.000" puede leerse como (a) la clase *es* "precio > 300k", o (b) el modelo solo aplica a propiedades de más de 300k. La apuesta es (a); se confirma con los datos en la etapa 3.
3. **Sobre la fuga de información.** Si la clase es función del precio y el precio *está* en casas_predecir.csv, eso **no es leakage**: hay fuga cuando se usa información que no estará disponible al predecir. Descubrir la regla es lo que hay que hacer y es defendible. La trampa más probable es otra: que el precio falte o esté vacío en el archivo de predicción, o que esté en otra moneda. En ese caso, el trabajo real es estimar si el precio supera 300k a partir de superficie, ambientes, ubicación, etc.
4. **La referencia de 166k permite estimar el tamaño del problema.** 166k es aproximadamente 500k × 1/3, lo que sugiere que casas_predecir tiene un tamaño parecido al train completo. Es un supuesto que se verifica al cargar.
5. **Detalles menores:** el PDF dice "target embedding" (lo usual es *target encoding*); el PDF mezcla "casas" y "departamentos" (inconsistencia del propio enunciado). El resto del resumen (URLs, fecha 22/10/2026, dos entregas, ids de casas_predecir, set_index("id"), campos sugeridos para excluir) coincide con el PDF.

B. Dudas para consultar con el docente

1. ¿"Acierto" incluye los "no paga" correctos, o solo cuentan los "paga" entregados? (Lectura A o B.)
2. ¿La clase se define como precio > US$ 300.000, o los 300k son un filtro de qué propiedades se evalúan?
3. ¿Cuál es el **formato exacto** de casas_entrega.csv? ¿Solo la columna id? ¿Con encabezado? ¿Qué separador? ¿O hay que incluir también la columna de clase con "paga"?
4. ¿Las dos entregas pueden venir de modelos distintos? ¿Llevan nombres distintos (casas_entrega_1.csv, casas_entrega_2.csv)?
5. ¿Se incluyen todas las operaciones y tipos de propiedad, o solo ventas? Si hay precios en ARS, ¿hay que convertirlos? ¿Con qué tipo de cambio?
6. ¿Se puede usar casas_predecir.csv (sin etiqueta) en pasos no supervisados, como clustering de ubicaciones con ambos archivos? Recomendación: no hacerlo salvo autorización.

C. Plan por etapas

1. Carga y primer vistazo

Qué hacemos: Cargar ambos CSV con id como índice; comparar forma, columnas, tipos y head().

Trampas:

- Columnas presentes en un archivo y no en el otro, sobre todo **si price existe y tiene datos en predecir**.
- Ids duplicados dentro de un archivo o compartidos entre ambos.
- Filas duplicadas.
- La clase en predecir es solo relleno ("no paga").

Terminado cuando: Tabla comparativa de ambos archivos y lista de diferencias anotada.

2. Análisis exploratorio (EDA) y calidad de datos

Qué hacemos: Revisar nulos por columna, distribuciones y proporción de clases.

Trampas:

- Precios en 0 o absurdos.
- Superficie cubierta mayor que la total.
- Monedas mezcladas (currency).
- operation_type distinto de venta.
- Países distintos de Argentina en l1.
- Outliers.
- Distribuciones distintas entre train y predecir.

Terminado cuando: Listado de problemas, cada uno con una decisión propuesta y su justificación.

3. Descubrir la regla de la clase

Qué hacemos: Cruzar la clase con precio, moneda, operación y tipo de propiedad (p. ej. % de "paga" con precio > 300k vs. el resto).

Trampas:

- Casos que contradicen la regla y en qué se diferencian (¿moneda? ¿operación?).
- Filas sin precio.

Terminado cuando: Regla escrita con su tasa de cumplimiento (p. ej. "la regla X explica el 99,x% de los casos; las excepciones son Y").

4. Limpieza

Qué hacemos: Aplicar las decisiones del EDA y documentar qué filas se descartan del **train** y por qué.

Trampas:

- Nunca borrar filas de **predecir**: hay que predecir sobre todas. Ahí solo se imputa o se marca.

Terminado cuando: Train limpio y predecir con el mismo número de filas que al inicio.

5. Feature engineering

Qué hacemos: Construir variables nuevas: precio por m² y ratios de superficie; indicadores de nulo; variables de fecha (año, mes); palabras clave del title ("pileta", "amenities"); target encoding de l3/l4/l5.

Trampas:

- El target encoding se ajusta **solo** con train y dentro de cada fold de la validación cruzada; si no, hay fuga.

Terminado cuando: Cada variable nueva tiene su explicación y una prueba de que aporta.

6. Validación y función de ganancia

Qué hacemos: Split 70/30 estratificado con random_state=42; Pipeline de scikit-learn para que todo el preprocesamiento se ajuste solo con train; función ganancia() con ambas lecturas (A y B).

Trampas:

- Usar el test para tomar decisiones: se mira una sola vez, al final de cada comparación.

Terminado cuando: Función probada con un ejemplo calculado a mano.

7. Modelo base

Qué hacemos: Modelo simple (árbol de decisión o regresión logística) sin los campos de alta dimensionalidad. Es la vara a superar: el PDF pide mejorar el modelo original. Se mide ganancia, precision, recall y AUC; la accuracy no sirve con clases desbalanceadas (predecir siempre "no paga" ya da accuracy alta).

Terminado cuando: Ganancia del test con ambas lecturas, comparada contra la referencia de ~166k.

8. Umbral óptimo

Qué hacemos: Buscar el umbral con predicciones out-of-fold de la validación cruzada (sin mirar el test) y compararlo con el teórico (1/3 o 0,6).

Trampas:

- Probabilidades mal calibradas (p. ej. Random Forest). Si el umbral empírico es inestable entre folds, usar el teórico.

Terminado cuando: Umbral elegido con su justificación.

9. Modelos alternativos

Qué hacemos: Random Forest y Gradient Boosting (HistGradientBoosting de scikit-learn). XGBoost o LightGBM solo si mejoran claramente.

Trampas:

- Sobreajuste: se detecta si la ganancia en CV es mucho mejor que en test.

Terminado cuando: Tabla comparativa con ganancia en CV (media +/- desvío) y en test.

10. Escalar la ganancia

Qué hacemos: Estimar la ganancia sobre casas_predecir: ganancia del test × (filas de predecir / filas del test), ajustada si la proporción esperada de positivos difiere.

Trampas:

- Asumir que la distribución de predecir es igual a la del train: se chequea con lo visto en la etapa 2.

Terminado cuando: Saber si superar los US$ 500.000 es plausible.

11. Predicción final y entregable

Qué hacemos: Reentrenar el modelo elegido con todo el train, predecir sobre casas_predecir y exportar solo los "paga".

Trampas:

- Verificar con assert: todos los ids están en predecir; ninguno pertenece solo al train; sin duplicados; formato acordado y sin columna de índice extra.

Terminado cuando: El CSV pasa los assert y se relee desde disco para confirmarlo.

12. Estrategia de dos entregas

Qué hacemos: Las dos entregas cubren la duda que no se pueda resolver. Si el docente no aclara la lectura: entrega 1 con el umbral de la lectura A (~1/3, más agresiva) y entrega 2 con el de la lectura B (~0,6, más conservadora). Si se aclara, la segunda entrega puede ser otro modelo u otro conjunto de variables.

Terminado cuando: Ambas entregas justificadas en el notebook.